AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad YUSUF DURSUN · 230541104 **Grup** GÜNDÜZ B **Tarih**

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: Vince YZ'li görsel **bağlama (sapan) kontrolü** eklenmesi planlanıyor: kanca kamerası, sapanın doğru bağlandığını ve kanca emniyet mandalının kapalı olduğunu kontrol edip kaldırma iznini veriyor — proje aşaması değerlendirmesi yapıyorsunuz. Aşırı yük, limit ve acil stop zinciri YZ'den tamamen ayrıdır.

Kanca kamerası → **YZ Modeli** → **OK / RED** → **Kaldırma izni / blokaj** ret mekanizması → **Kaldırma hızı** YZ yalnız düşürebilir

Görev — üç başarısızlıkta güvenli davranış

1 Model yanlış sınıflandırdı: Hatalı bağlanmış yüke OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Sonuç yük düşmesi olabilir (S=3); bu yüzden **YZ'nin OK'i tek başına kaldırma izni vermez**. İkinci kontrol: sapancı/operatörün bağlamayı onaylaması zorunludur (**human override**). Kaldırma ilk 20–30 cm'de yavaş "deneme kaldırması" ile başlar; yük hücresi dengesiz yük veya ani yük değişimi görürse kaldırma durur. YZ kararlarının hata oranı izlenir (**monitoring**), artarsa YZ devre dışı → yalnız insan kontrolü (**fallback**).

2 Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Fark etme: kamera heartbeat ve kare sayacı/zaman damgası kontrolü, donmuş kare tespiti, kanca üzerindeki sabit referans işaretinin her karede doğrulanması, lens kapanması/bulanıklık ve parlaklık anomalisi tespiti, kamera–PLC arasında kimlik doğrulamalı bağlantı.
Şüpheli girdide (fail-safe): YZ kararı geçersiz; kaldırma izni verilmez veya yalnız yavaş hızda ve operatörün görsel onayıyla yapılır; alarm verilir, olay kaydedilir.

3 Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Örnek eşikler (validasyon verisiyle kesinleşir): **güven ≥ %95 → kaldırma önerilir** (yine operatör onayıyla) · **%80–95 → insana sor** (operatör yakından görsel kontrol yapar, yavaş hız) · **< %80 → kaldırma izni yok**, bağlama yeniden yapılır. Düşük güven sıklaşırsa YZ devre dışı, manuel kontrol (fallback). YZ yalnız hızı düşürebilir veya kaldırmayı engelleyebilir; asla hızı artıramaz veya emniyet limitlerini aşamaz.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	**Human override + monitoring:** OK tek başına yetmez, sapancı onayı + yavaş deneme kaldırması + yük hücresi kontrolü; hata artarsa YZ kapalı (**fallback**).
Girdi manipüle edildi	**Fail-safe + monitoring:** girdi bütünlüğü kontrolü; şüphede kaldırma izni yok veya yalnız yavaş hız + insan onayı, alarm.
Confidence düştü	**Confidence threshold + human override + fallback:** ≥%95 öneri, %80–95 insan kontrolü, <%80 izin yok; sürekli düşükse YZ kapalı, manuel kontrol.

📄 Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.